

MCP 调用链卡顿问题调试复盘

从怀疑 Tavily 到定位 LangSmith 追踪

适用项目 agent-dev-lab

复盘日期 2026 年 9 月 15 日

核心结论

Tavily API、Tavily Key、search_jobs 函数和 FastMCP 调度均能独立完成。卡顿只在 MCP stdio 子进程启用 LangSmith 自动追踪时出现。该子进程的 LangSmith 请求经过本机 Clash Verge Mihomo 代理端口 127.0.0.1:7897 后没有及时完成，使 web_search.ainvoke 一直等待追踪相关回调。

本文记录完整排查过程，并给出在保留 LangSmith 追踪的前提下检查 endpoint、代理规则、工作区配置和 MCP 子进程环境的方法。

摘要与建议

这次问题最容易误判的原因，是日志最后停在 `search_jobs` 内部、`Tavily` 调用之前。表面现象指向 `Tavily`，但控制变量实验显示 `Tavily` 本身能够正常返回，真正的差异变量是 `LangSmith tracing` 是否启用。

已经确认的事实

- `TAVILY_API_KEY` 能从 `.env` 读取，非空、无首尾空格，格式符合 `tvly` 前缀。
- 同一虚拟环境在正常网络权限下调用 `Tavily`，API 响应时间约 0.88 秒并返回 5 条结果。
- 直接调用 `search_jobs` 成功；直接通过 `FastMCP` 工具调度器调用也成功。
- 通过 `MCP stdio` 子进程调用且 `tracing` 为 `true` 时，程序进入 `search_jobs` 后持续等待。
- 把 `LANGSMITH_TRACING=false` 明确传给 `MCP` 子进程后，完整 `MCP` 调用约 4.27 秒完成。
- 卡住的 `MCP` 子进程连接到了 `127.0.0.1:7897`，该端口由 `verge-mihomo.exe` 监听。

保持追踪时的处理顺序

1. 确认 `LangSmith` 账号所在区域，并设置正确的 `LANGSMITH_ENDPOINT`。
2. 让 `Clash Verge Mihomo` 对 `LangSmith` 域名使用可用代理节点，不要命中 `REJECT` 或异常的 `DIRECT` 规则。
3. 如 API Key 关联多个 `workspace`，设置 `LANGSMITH_WORKSPACE_ID`。
4. 在 `MCP connection` 的 `env` 字段中显式传递 `LangSmith` 配置，不依赖子进程碰巧找到项目根目录下的 `.env`。
5. 按 `LangSmith` 连通性测试、`search_jobs` 单测、`MCP` 工具测试、`main.py` 的顺序逐层回归。

结论的边界

实验已经证明 `tracing` 为 `true` 是 `MCP` 卡顿的必要差异条件，并证明关闭 `tracing` 后链路恢复。当前证据还不能把更底层原因唯一归为某条 `Clash` 规则、某个代理节点、`LangSmith` 区域 `endpoint` 或账号 `workspace` 配置。后续应使用有超时的 `LangSmith Client` 测试继续区分这些可能性。

系统调用链

先把程序拆成可独立验证的层，才能知道一次卡顿究竟属于业务函数、第三方 API、框架包装还是进程通信。

```
main.py
-> run_career_agent
  -> LangGraph agent
    -> MCP client
```

```
-> stdio 启动 Python 子进程
-> career_server.py
-> search_jobs
-> TavilySearch.ainvoke
-> api.tavily.com/search
-> api.smith.langchain.com 追踪上报
```

TavilySearch.ainvoke 不只是一次 HTTP 搜索。当全局 tracing 开启时，LangChain 还会创建 trace、记录输入和输出，并由 LangSmith 客户端上传。因此，ainvoke 停住并不能单凭最后一条业务日志判断是 Tavily 请求停住。

涉及的项目位置

位置	作用	本次观察
main.py	启动完整 Agent	完整链路变量最多，不适合作为第一层定位工具
framework_agent/agent.py	创建 Agent 并调用模型和工具	模型、RAG、MCP、追踪都会混在一次运行中
mcp_clients/career_client.py	通过 stdio 创建 MCP 子进程	子进程环境由 MCP SDK 重新组装
mcp_servers/career_server.py	注册 search_jobs 并调用 Tavily	日志停在第 43 行附近
.env	保存 API Key 和 tracing 配置	LANGSMITH_TRACING=true

为什么完整 main.py 不适合一开始就反复运行

完整 Agent 同时依赖大模型接口、MCP 子进程、Tavily、向量库和 LangSmith。任何一层失败都可能覆盖下一层的真实状态。本次受限环境运行 main.py 时，大模型连接先报 OpenAIConnectionError，程序甚至没有机会进入 search_jobs。这不是 Tavily 的证据，只说明完整测试无法隔离变量。

初始现象和假设

已知现象是 search_jobs 被调用后程序报错或长时间没有返回。最初不能直接认定 Tavily 故障，需要同时保留多种解释。

假设	如果成立应看到什么	验证方法
----	-----------	------

假设	如果成立应看到什么	验证方法
Tavily Key 缺失或格式错误	对象初始化失败，或服务返回 401 403	只检查是否存在、长度和前缀，不打印密钥
Tavily 参数写错	ainvoke 本地校验报 ValidationError	查看工具签名并直接调用
Tavily 服务不可达	无法建立 api.tavily.com 的 HTTPS 连接	隔离 Tavily 并在正常网络权限下执行
MCP 包装层出错	直接函数成功，MCP 调用失败	建立有无 MCP 的对照组
追踪系统阻塞	tracing true 卡住，false 恢复	只改变 tracing 一个变量
终端编码问题	结果已返回，但打印含特殊字符时报 UnicodeEncodeError	区分计算完成与输出失败

第一原则 先确定卡在哪一层

面对长调用链，调试不是从最复杂的入口反复尝试，而是逐层建立最小可运行实验。每次实验只回答一个问题，并保留一个对照组。

第二原则 区分事实和解释

日志显示 search_jobs entered 是事实。把它解释为 Tavily 挂了仍然只是一个假设。只有把 Tavily 单独调用成功、MCP 调用失败、关闭 tracing 后恢复这三组证据放在一起，才足以把故障范围收敛到追踪链路。

逐步调试记录

步骤一 阅读调用链和配置

先查看 main.py、Agent、MCP client、MCP server、Tavily 测试文件以及 .env 的变量名。没有打印任何 Key 内容，只检查变量是否存在、字符串长度、首尾空格和已知前缀。

```
检查结果
TAVILY_API_KEY: 已加载，长度 57，以 tvly 开头
LANGSMITH_TRACING: true
LANGSMITH_PROJECT: agent-dev-lab
```

这一结果排除了 Key 完全没加载，但不能证明 Key 有效。只有 Tavily 服务器返回成功结果才能验证 Key。

步骤二 检查 Tavily 的异常处理方式

检查已安装的 langchain-tavily 源码后发现，TavilySearch 的异步实现会捕获普通异常并返回一个 error 字典，而不是继续抛出异常。career_server.py 又执行 return str(result)。因此 MCP 可能把网络失败当成普通字符串返回，错误位置会被掩盖。

```
except Exception as e:
    return {"error": e}

# 项目代码随后执行
return str(result)
```

这个设计不是本次卡顿的根因，但它解释了为什么日志和错误表现容易令人误判。

步骤三 受限环境中的第一次复现

最初在受限诊断环境中直接运行 Tavily 测试，得到 ClientConnectorError 和 PermissionError 13。LangSmith 也同时连接失败。这个结果只能说明当前诊断容器不允许外网连接，不能直接代表用户电脑。

```
ClientConnectorError(host='api.tavily.com', port=443,
PermissionError(13, '拒绝访问'))
```

这里出现了本次调试中的一次错误方向：把受限执行环境的网络策略当成了项目真实故障。

步骤四 使用浏览器证据纠正判断

浏览器访问 api.tavily.com 返回 JSON message Alive，证明 Tavily 域名和浏览器网络链路可达。这仍不能验证 Python 的 POST 请求和 API Key，但足以否定电脑完全无法访问 Tavily 的说法。于是需要在用户明确授权后，用正常网络权限执行隔离测试。

步骤五 在正常网络权限下隔离 Tavily

运行项目中已有的 test_tavily.py，并临时在当前进程关闭 LangSmith tracing，确保测试只回答 Tavily 是否正常。

```
$env:LANGSMITH_TRACING='false'
python -m agent_dev_lab.test_tavily
```

观测项	结果
-----	----

观测项	结果
进程耗时	约 3.09 秒
Tavily API response_time	0.88 秒
结果数量	5 条
API Key	认证成功
结论	Tavily API、Key、查询参数和异步调用方式均正常

步骤六 运行完整 MCP 工具链

随后运行已有的 test_career_client.py。MCP 能完成 ListToolsRequest，也能发出 CallToolRequest，服务端打印 search_jobs entered，但超过 60 秒没有返回结果。

```
Processing request of type ListToolsRequest
Processing request of type CallToolRequest
1. search_jobs entered
# 此后持续等待
```

这一步把问题范围从 Tavily 缩小为 MCP 路径中的某个差异，但还不能判断是 FastMCP 调度、stdio 通信、子进程环境还是 tracing。

步骤七 直接调用同一个 search_jobs

跳过 MCP client 和 stdio 子进程，直接导入并运行 career_server.py 中的 search_jobs。相同中文查询约 3.82 秒成功返回。

这说明 search_jobs 函数、全局 TavilySearch 对象、中文查询和 async await 写法本身没有问题。故障只在进入 MCP 子进程路径后出现。

步骤八 直接调用 FastMCP 调度器

为了区分 FastMCP 调度器和 stdio 子进程，再通过 mcp.call_tool 直接调用已注册工具。约 2.47 秒成功返回。

至此可以排除 FastMCP 的工具注册和调度逻辑，剩余重点是 stdio 子进程环境及其网络副作用。

步骤九 观察卡住进程的网络状态

在 MCP 测试卡住时，读取 Python 进程树和 TCP 连接。子进程没有直接显示到 Tavily 的公网连接，而是连接到本机 127.0.0.1:7897。该端口的监听进程是 verge-mihomo.exe，即 Clash Verge Mihomo 的代理核心。

观测	含义
MCP server 是 client 启动的子进程	stdio 进程模型符合预期
子进程连接 127.0.0.1:7897	请求经过本机代理
连接保持 Established 或进入 CloseWait	连接建立过，但响应或关闭流程未正常完成
直接 Tavily 调用成功	代理并非对所有域名和所有 Python 请求都不可用

步骤十 检查 MCP 子进程环境继承

MCP SDK 的 stdio_client 不会完整继承父进程环境，而是只传递 APPDATA、PATH、TEMP、USERPROFILE 等白名单变量。父进程临时设置的 LANGSMITH_TRACING=false 不在白名单中。

```
DEFAULT_INHERITED_ENV_VARS = [  
    'APPDATA', 'HOMEDRIVE', 'HOMEPATH', 'LOCALAPPDATA',  
    'PATH', 'PATHEXT', 'PROCESSOR_ARCHITECTURE', 'SYSTEMDRIVE',  
    'SYSTEMROOT', 'TEMP', 'USERNAME', 'USERPROFILE'  
]
```

子进程启动后，career_server.py 又调用 load_dotenv，因此它重新从项目 .env 读取 LANGSMITH_TRACING=true。于是父进程看似关闭追踪，MCP 子进程实际上仍然启用了追踪。

步骤十一 只改变 tracing 变量

最后建立关键对照组：其他代码、Key、查询、MCP transport 和代理都保持不变，只在 MCP connection 的 env 中明确传入 LANGSMITH_TRACING=false。

实验	Tracing	结果	耗时
MCP stdio 原配置	true	进入 search_jobs 后持续等待	> 60 秒
MCP stdio 对照配置	false	工具返回搜索结果	约 4.27 秒

对照测试返回结果后，诊断命令在向 GBK 终端打印特殊字符时出现 UnicodeEncodeError。这个错误发生在结果已经返回之后，属于诊断输出编码问题，不影响 tracing 对照实验的结论。

推理如何收敛

问题	实验	结论
Key 是否缺失	只读检查 .env	否，Key 已加载
Key 是否有效	正常网络下请求 Tavily	是，返回 5 条结果
query 参数是否错误	直接 ainvoke	否
search_jobs 是否错误	直接调用同一函数	否
FastMCP 调度是否错误	直接 mcp.call_tool	否
stdio 路径是否相关	MCP client 完整测试	是，只在该路径卡住
tracing 是否关键变量	仅切换 tracing true false	是，false 时恢复
Tavily 是否是最终根因	综合全部对照	否

确认结论

MCP stdio 子进程启用 LangSmith tracing 时，search_jobs 的 LangChain 调用无法及时完成。关闭 tracing 后，同一调用链恢复。Tavily 只是被追踪的那次运行，不是失败的第三方服务。

最可能的底层机制

LangSmith 会在 LangChain 调用前后记录 run，并访问 api.smith.langchain.com 获取服务信息和上传 trace。卡住进程的连接经过 Clash Verge Mihomo。结合此前出现的 LangSmithConnectionError，最可能的机制是 LangSmith 域名对应的代理路由、代理节点、TLS 链路或区域 endpoint 没有正常完成，而 tracing 回调延长了 ainvoke 的完成时间。

尚未完全证明的部分

- 具体是哪一条 Clash 规则或哪个代理节点导致 LangSmith 请求停住。
- LangSmith 账号属于 US、APAC、EU 还是 AWS US 区域。
- API Key 是否关联多个 workspace，是否必须设置 LANGSMITH_WORKSPACE_ID。
- 直接调用 LangSmith Client.info 时会返回成功、认证错误还是网络超时。

保留这些不确定性很重要。好的调试报告应说明证据能证明什么，也要说明还没有证明什么。

保留 LangSmith 追踪的修改建议

目标不是关闭追踪，而是让 MCP 子进程稳定、明确地连接到正确的 LangSmith endpoint，并让网络失败能够快速暴露。建议按以下顺序处理。

第一步 确认 LangSmith 区域

LangSmith 官方文档说明，默认 endpoint 是 US Cloud。账号如果位于 APAC 或 EU，必须使用对应区域地址，否则 Key 可能无法正确认证。

```
# US Cloud
LANGSMITH_ENDPOINT=https://api.smith.langchain.com

# APAC
LANGSMITH_ENDPOINT=https://apac.api.smith.langchain.com

# EU
LANGSMITH_ENDPOINT=https://eu.api.smith.langchain.com
```

在 LangSmith 控制台确认账号区域，只保留其中一个 endpoint。不要因为人在中国就直接假定账号一定属于 APAC；以账号实际部署区域为准。

第二步 检查 Clash Verge Mihomo 规则

在 Clash 连接日志中搜索 smith.langchain.com。确认它没有命中 REJECT，也不要使用无法访问该域名的异常节点。可以先用一条范围较窄的规则进行验证，代理组名称需要替换成自己的实际名称。

```
DOMAIN-SUFFIX,smith.langchain.com,PROXY
```

修改规则后，先在浏览器访问 <https://api.smith.langchain.com/info>。能快速返回 JSON 或明确的 401 403，都比一直加载更有价值：前者说明服务可达，后者说明网络可达但认证或区域配置还需处理。

第三步 完善 .env

```
LANGSMITH_TRACING=true
LANGSMITH_API_KEY=<现有 LangSmith Key>
LANGSMITH_PROJECT=agent-dev-lab
LANGSMITH_ENDPOINT=https://api.smith.langchain.com
# 仅当 Key 可访问多个 workspace 时添加
# LANGSMITH_WORKSPACE_ID=<Workspace ID>
```

不要把 Key 写进 Python 文件，也不要再在日志中打印 Key。官方文档指出，多 workspace Key 才需要 LANGSMITH_WORKSPACE_ID。

第四步 显式传递 MCP 子进程环境

虽然当前子进程能通过工作目录找到 .env，但显式传递配置更可靠，也允许父进程覆盖某个变量进行诊断。以下是建议结构，Key 仍从环境变量读取。

```
import os
from dotenv import load_dotenv

load_dotenv()

langsmith_env = {
    name: os.getenv(name)
    for name in (
        'LANGSMITH_TRACING',
        'LANGSMITH_API_KEY',
        'LANGSMITH_PROJECT',
        'LANGSMITH_ENDPOINT',
        'LANGSMITH_WORKSPACE_ID',
    )
    if os.getenv(name)
}

# 在 career connection 内增加
'env': langsmith_env,
```

这项修改解决的是子进程配置可预测性，不能替代 endpoint 和代理连通性修复。如果 LangSmith 域名仍无法访问，显式传入 tracing=true 仍然会卡住。

第五步 用短超时测试 LangSmith

先单独验证 LangSmith，不要直接运行 main.py。下面的诊断只请求服务信息，不运行 Agent。timeout_ms 可以避免网络异常时等待很久。

```
from dotenv import load_dotenv
from langsmith import Client

load_dotenv()
client = Client(timeout_ms=(5000, 10000))
print(client.info)
```

如果该测试在 10 秒内返回信息，说明 endpoint、代理和基本客户端连接已正常。若快速返回 401 或 403，重点检查 Key、区域和 workspace；若连接超时，重点检查 Clash 规则和代理节点。

第六步 分层回归

- 6. 先运行 LangSmith Client.info，确认追踪服务可达。
- 7. 运行 test_tavily.py，确认搜索不受追踪影响。
- 8. 运行 test_career_client.py，确认 MCP 子进程能返回。
- 9. 最后运行 main.py，验证模型、RAG、MCP 和 tracing 的组合。
- 10. 到 LangSmith 控制台确认 agent-dev-lab 项目出现完整 trace。

建议的失败判读表

现象	优先检查
Client.info 超时	代理规则、节点、DNS、TLS、endpoint 可达性
Client.info 返回 401	API Key 和区域 endpoint
Client.info 返回 workspace 错误	LANGSMITH_WORKSPACE_ID
LangSmith 单测成功但 MCP 卡住	career connection 的 env 与 cwd
MCP 成功但 main.py 失败	模型接口、RAG 或 Agent 逻辑

可复用的调试方法

一 画出调用链

先写出入口、框架、子进程、业务函数、第三方服务和旁路服务。旁路服务包括日志、监控和 tracing，它们经常被忽略，却可能改变主调用的完成时间。

二 建立最小复现

从最靠近外部依赖的一层开始。本次先测试 Tavily，再测试 search_jobs，再测试 FastMCP，最后才测试 stdio MCP。每增加一层，如果结果从成功变为失败，新增的那一层就是重点。

三 一次只改变一个变量

最后的 tracing true false 对照最有证明力，因为其他条件没有变化。若同时更换 Key、代理、包版本和代码，就无法知道是哪项修改生效。

四 为每一层设置观测点

进入函数 -> 构造参数 -> 外部调用前 -> 外部调用后 -> 返回前
进程层面 -> PID 和父子关系 -> TCP 目标 -> 连接状态
配置层面 -> 变量是否存在 -> 来源 -> 是否传给子进程

观测点应该记录状态和耗时，不应打印密码、Token、完整简历或其他敏感内容。

五 对环境差异保持警惕

浏览器、IDE、普通终端、受限沙箱和 MCP 子进程可能使用不同的代理、证书、环境变量和工作目录。某个环境中失败，不足以推出另一个环境也失败。

六 主动寻找反证

看到 PermissionError 后，浏览器 Alive 页面是重要反证。好的调试不是不断收集支持原假设的证据，而是设计能够推翻原假设的实验。

七 记录结论边界

本次可以确认 tracing 是关键差异变量，但不能仅凭现有证据断言具体某条 Clash 规则错误。把已确认事实、最可能解释和未验证项分开，能够避免在修复时再次走偏。

常见误区

误区	为什么不可靠	更好的做法
最后一条日志在 Tavily 前，所以 Tavily 挂了	ainvoke 还包含 tracing 回调	拆开测试 Tavily 和 tracing
浏览器能打开，所以 Python 一定能访问	代理、证书和请求方式可能不同	用同一虚拟环境发出实际请求
Key 存在，所以 Key 一定有效	存在只证明加载，不证明服务接受	观察服务端成功或明确状态码

误区	为什么不可靠	更好的做法
完整 main.py 报错就是目标模块报错	更早的模型调用可能先失败	从外部依赖开始逐层增加组件
关闭 tracing 能运行，所以问题解决 了	这只是绕过，不满足保留追踪的目标	修复 endpoint 代理和子进程配置
一次修改很多配置更快	无法建立因果关系	每次只改变一个变量并记录耗时

通用排查清单

- ☐ 复现问题并记录完整异常链、最后日志和耗时。
- ☐ 画出调用链，标记进程边界和第三方服务。
- ☐ 检查配置是否存在，但不输出秘密值。
- ☐ 隔离最底层外部依赖并验证 Key 和网络。
- ☐ 逐层加入业务函数、框架包装和进程通信。
- ☐ 建立成功与失败的对照组，一次只改变一个变量。
- ☐ 卡顿时检查进程树、网络目标和连接状态。
- ☐ 检查父进程与子进程的环境变量、cwd、编码和代理差异。
- ☐ 把根因、伴随问题和诊断噪声分开。
- ☐ 修复后按从小到大的顺序回归，并确认监控端收到数据。

本次证据时间线

阶段	测试	结果	推理变化
代码阅读	检查 main 到 Tavily 的调用链	定位调用点和 tracing 配置	形成多假设列表
配置检查	只看 Key 状态和前缀	Tavily Key 已加载	排除完全缺失
受限环境	隔离 Tavily	PermissionError 13	产生网络怀疑，但证据受环境限制
浏览器反证	访问 api.tavily.com	返回 Alive	纠正电脑无网的过度结论

阶段	测试	结果	推理变化
正常权限	test_tavily.py	5 条结果, API 0.88 秒	排除 Tavily API Key 参数
完整 MCP	test_career_client.py	进入函数后 > 60 秒等待	锁定 MCP 路径差异
直接函数	search_jobs	约 3.82 秒成功	排除函数实现
FastMCP 调度	mcp.call_tool	约 2.47 秒成功	排除工具注册和调度
进程观察	TCP 和监听进程	连接 verge-mihomo 7897	发现代理路径
环境检查	stdio 环境白名单	父进程覆盖不自动传递	发现子进程配置差异
最终对照	子进程 tracing=false	约 4.27 秒返回	确认 tracing 为关键差异变量

诊断过程中没有做的事情

- 没有修改项目源代码、.env 或 API Key。
- 没有把任何完整密钥写入终端输出或报告。
- 一次性 Python 对照代码通过 python -c 在进程内执行，没有保存到项目源码目录。
- 没有终止用户已经启动的 main.py 和 MCP 子进程。

参考资料

以下资料用于核对 LangSmith tracing、endpoint、workspace 和按运行时传递环境配置的官方要求。

1. [LangSmith 创建账号和 API Key](#)
2. [LangChain 应用启用 LangSmith tracing](#)
3. [不依赖环境变量的 tracing 配置](#)
4. [LangSmith profile 和 endpoint 优先级](#)
5. [沙箱运行时传递 tracing 环境](#)

最后的学习重点

这次调试最值得复用的能力，不是记住 `LANGSMITH_TRACING` 这个变量，而是把复杂系统拆成可以独立验证的层，并通过对照实验寻找唯一差异。看到一个错误时，先问它属于哪个环境、哪一层、由谁抛出、是否被包装，以及什么实验能够推翻当前猜测。